

Modulo 3. Alineamiento de a Pares

El objetivo de este modulo es que usted aprenda, programe, y use diferentes algoritmos y componentes de los algoritmos de alineamiento. Dicen que uno realmente comprende algo si puede programarlo, y por eso lo que buscamos es que luego de este modulo usted realmente comprenda el concepto y técnica fundamental de la bioinformatica que es el alineamiento de secuencias. Dada la complejidad del problema, separaremos el mimos en etapas y objetivos específicos.

Modulo 3.1 Programar un algoritmo de alineamiento

El objetivo de este modulo es programar un algoritmo completo de alineamiento, primero para ADN y luego para proteínas.

Vamos a empezar de a poco, y de acuerdo a lo aprendido en IBM empecemos por el famoso Dot-Plot

Objetivo 3.1) Programar algoritmos de tipo Dot-plot

Comenzaremos comparando secuencias utilizando el método gráfico de dot-plot, aprovechando conocimientos de la clase anterior y viendo de paso un poco de Numpy (librería de python para manejar matrices). Lo primero es levantar dos secuencias (por ejemplo seq1.fasta y seq2.fasta u otras que usted baje y/o tenga de su interés), luego convertirlas a formato "String", y usar "numpy" para construir una matriz (el dot-plot), con una matriz de puntuación simple 0=mismatch, 1=match

Veamos primero como funciona brevemente numpy:

```
Import numpy as np
mi_matriz=np.zeros((filas,columnas))
```

Esto crea una matriz de zeros filas x columnas

Luego se pueden llenar y acceder usando indices de manera similar a lo que se hace con listas.

```
mi_matriz[0][1]=1
mi_matriz[2][0]=2
mi_matriz
```

numpy permite realizar luego montón de operaciones matemáticas, de matrices etc. (si quiere explorelo un poco con su amigo ChatGPT

Ejercicio 3.1 Dot-Plot y filtros

a) cree una matriz de ceros (de dimensión de acuerdo a las longitudes de seq1 y seq2) y luego recorra todas las casillas poniendo 1 donde hay un match y 0 donde hay mismatch (consejo pruebe con una matriz más pequeña y luego vaya por la completa).


b) Arme un modulo para graficar el dot-plot.

Analice los resultados. Notará que para secuencias largas (de ADN) el dot-plot se ve muy “congestionado”. Para corregir ese problema se suele utilizar un **filtro** por un tamaño de ventana (window-size) tal que solo se muestra un “dot” en el caso de que la cantidad de bases “matches” supera ese umbral.


c) Programe un filtro que opere sobre el dot-plot obtenido (el window-size “w” debería ser una variable a modificar), y reanalice los resultados. Hay varias alternativas para programar el filtro, como ser relacionadas con si las ventanas se encuentran superpuestas o son adyacentes, y si el dotplot es reemplazado por el dotplot de las ventanas y/o las mismas son solo utilizadas como filtro. Además se puede setear el umbral (vea el grafico para mayor claridad). Programe y compare las diferentes opciones.

Gráfico de Filtros:

Filtro y reducción



Filtros solapados



Un alineamiento, derivado de un dot-plot, no es otra cosa que un camino “único” sobre el mismo. Recuerde que en un dot plot, el camino tiene pasos de tres tipos, Diagonal (D), Vertical (V) y Horizontal(H), que un paso por la diagonal puede alinear o corresponder tanto a un “match” como a un “mismatch” y que los pasos V y H implican insertar/extender gaps. Par ir desde nuestro dot-plot al alineamiento entonces lo que debemos hacer es un algoritmo que recorra el dot plot, y genere un camino (comenzando en la esquina arriba-izquierda y yendo hacia el limite derecho u inferior e idealmente a la esquina abajo-derecha)

3.1d) Programe un algoritmo que recorra un dot-plot (de unos y ceros y obtenga un buen (o el mejor) camino posible.

Consejo: Piense/Discuta como recorrería el dot-plot y que decisión tomaría a cada paso utilizando el principio de Dividir y Conquistar!

e) Obtenga el camino como una serie de coordenadas y dibújelo sobre el dot-plot

f) Analice sobre el camino el efecto de utilizar secuencias con diferente grado de identidad, diferente largo, y el uso de los filtros programado en el punto anterior.

g) Busque algún programa on-line (BLAST?) que haga alineamientos compare los resultados de su algoritmo con el obtenido con BLAST hasta estar conforme de que su algoritmo de búsqueda de camino es lo suficientemente bueno.

Del Dot-plot al alineamiento

El camino sobre el dot plot es ya un alineamiento, pero esta en un formato que no nos gusta. El desafio del tercer modulo del presente código es entonces convertir el camino que recorre el dot-plot en un alineamiento que podamos ver en pantalla de acuerdo a lo que estamos acostumbrados.

Para alineamiento de ADN (y veremos que es extensible a proteínas fácilmente) se sugiere utilizar el siguiente formato:

3 filas, donde fila 1 secuencia 1 (y sus gaps), fila 2 secuencia 2 y sus gaps. fila 3 (indicador de match, i.e *),

Por ejemplo:

ACGTTTCAGTAG

AC---CACTTG

** *** *

también puede cambiar f2 x f3:

ACGTTTCAGTAG

** *** *

AC---CACTTG

Nótese que si consideramos el índice de posición de cada una de las filas, lo que necesitamos es para una cadena de caracteres tal que la f1 y f2 tengan la secuencias 1 y 2 y sus gaps, y la f3 el indicador de match. Entonces..

31.h) Escriba un código que tome como entrada s1, s2 y el camino del dot-plot y sea capaz de mostrar el alineamiento en el formato deseado.

Notas: la dificultad está en cómo poner los gaps. Recuerde que ir por la Horizontal implica poner un gap en la secuencia vertical (usualmente s2) y vice-versa. Recomendamos no programar de entrada, sino resolver la lógica del código (para las opciones principales, D, H y V) en papel y luego ver cómo programarlo.

i) Busque algún programa on-line (BLAST?) que haga alineamientos compare los resultados de su algoritmo con el obtenido con BLAST

Alineamiento de proteínas (de a pares):

Antes de meternos con los alineamientos de proteínas revisemos/repasemos un poco algunos conceptos ideas, por ejemplo la Matriz de sustitución.

3.2 a) Busque una matriz de sustitución (Blossum60?). Levántela en python y luego de analizarla programe un código que haga un dot-plot para el alineamiento de 2 secuencias proteicas con la misma.

Notará que el problema es que la matriz está llena de números (a esta matriz la llamaremos matriz de comparación de las proteínas) y usted necesita convertirla en una de 1s y 0s (un dot-plot, por que?).

Para convertir su matriz de comparación de proteína en un dot-plot, vamos a retomar el concepto de filtros (utilizando en el objetivo 1).

b) programe un modulo que convierta la matriz de comparación en un dot-plot (de 1s y 0s) tomando como parametros: a) un window size y b) un umbral de puntaje para decir que convierte en 0 y que convierte en 1.

c) Combine ahora este modulo con los realizados para ADN y realice alineamientos de a pares entre distintas proteínas. Explore cómo varía el resultado en función de la identidad de secuencia, el uso de distintos tipos de filtros, y umbrales. Compare sus resultados con aquellos obtenidos por un programa como BLAST.

Si usted está conforme con los resultados obtenidos puede frenar acá... pero si tiene tiempo y ganas puede tratar de mejorar su programa con alguno(s) de los siguientes módulos.

d) Realice un programa que a partir de la matriz de comparación y utilizando filtros, obtenga un dot plot, pero no de 0s y 1s sino que contenga los valores REALES de la matriz (utilice el filtro para convertir celdas en 0 con algún umbral)

- e) Ahora modifique su algoritmo de búsqueda de caminos para que trabaje sobre el nuevo dot-plot
- f) Utilice los módulos d) y e) para realizar nuevos alineamientos y compare los resultados obtenidos con respecto a los anteriores y con ellos obtenidos por BLAST (u otro similar).